


RAG del pueblo

Agente de indagación de las conferencias matutinas del Gobierno Federal de México

Trabajo final Diplomado de Ingeniería en IA.
Reporte de razonamiento y arquitectura

Autor: Ricardo Angeles Gómez



Recuperación de información



Memoria conversacional



Arquitectura escalable



Al servicio de la ciudadanía



RAG del pueblo

Agente de indagación de las conferencias matutinas del Gobierno Federal de México

Trabajo final — Diplomado de Ingeniería en IA
Reporte de razonamiento y arquitectura

Autor: Ricardo Angeles Gómez

Resumen ejecutivo

Las conferencias matutinas del Gobierno Federal de México constituyen un corpus público, extenso y temporalmente continuo. Una misma materia puede aparecer en distintas fechas, ser abordada por diferentes participantes y evolucionar a lo largo del tiempo, lo que hace difícil localizar manualmente declaraciones específicas y reconstruir su contexto.

RAG del pueblo fue construido como un sistema de indagación sobre este corpus. Su objetivo no es determinar si una declaración es verdadera ni sustituir el análisis humano, sino facilitar la recuperación de evidencia, conservar su procedencia y generar respuestas que puedan rastrearse hasta los fragmentos utilizados.

El sistema combina un pipeline de datos con arquitectura medallón **Bronze** → **Silver** → **Gold**, búsqueda semántica mediante embeddings, generación aumentada por recuperación (RAG), memoria conversacional aislada por usuario y una capa pequeña de planificación que puede utilizar tres herramientas de consulta de solo lectura.

La arquitectura fue diseñada alrededor de una restricción principal: **una respuesta debe estar subordinada a la evidencia disponible en el corpus**. Cuando la recuperación no proporciona respaldo suficiente, el sistema debe abstenerse de presentar una conclusión.

La versión descrita en este reporte se encuentra desplegada en un entorno productivo de demostración en Cloud Run y utiliza PostgreSQL/pgvector como almacenamiento e índice vectorial.

URL productiva: `https://rag-del-pueblo-iens6os2ba-uc.a.run.app`

1. Contexto y problema

Las conferencias matutinas contienen información distribuida entre miles de fragmentos de texto. Una búsqueda convencional puede localizar coincidencias léxicas, pero resulta menos adecuada cuando la pregunta expresa una idea con palabras diferentes a las utilizadas en la fuente, cuando la información relevante está distribuida entre varias sesiones o cuando es necesario continuar una investigación durante varios turnos.

El problema planteado para este proyecto fue, por tanto, construir un mecanismo que permitiera consultar este corpus mediante lenguaje natural sin perder la relación entre una respuesta generada y las fuentes que la sustentan.

El sistema debía permitir recuperar declaraciones semánticamente relacionadas, mantener el contexto de una conversación, distinguir conversaciones y usuarios, explorar la estructura temática del corpus y proporcionar evidencia suficiente para inspeccionar por qué se generó una determinada respuesta.

El comportamiento esperado ante una consulta sin respaldo también forma parte del problema. Un sistema de recuperación no debería convertir la ausencia de información en una afirmación plausible generada por el modelo. Por esta razón, la negativa ante evidencia insuficiente se considera una característica funcional y no un error.

Los usuarios considerados para esta entrega son periodistas, analistas o investigadores que necesiten localizar declaraciones y reconstruir su procedencia. La demostración productiva utiliza dos usuarios independientes para verificar adicionalmente el aislamiento de la memoria conversacional.

2. Objetivo y alcance

El objetivo del proyecto es demostrar una arquitectura completa de IA aplicada capaz de transformar información pública en un corpus consultable mediante recuperación semántica y generación aumentada por recuperación.

El proyecto cubre cuatro responsabilidades diferentes:

Responsabilidad	Propósito
Ingeniería de datos	Ingerir, validar, transformar y conservar el corpus
Preparación del conocimiento	Fragmentar, generar embeddings e indexar información
Recuperación y generación	Recuperar evidencia y producir respuestas fundamentadas
Analítica exploratoria	Identificar agrupaciones temáticas y visualizar el espacio semántico

Esta separación es importante. Por ejemplo, la reducción dimensional y el clustering son capacidades analíticas de la capa Gold, pero **no forman parte del camino crítico requerido para producir una respuesta RAG**.

El sistema tampoco pretende realizar fact-checking, evaluar la veracidad de las declaraciones, inferir intenciones políticas ni sustituir una investigación periodística. Su responsabilidad termina en organizar, recuperar y presentar evidencia contenida en el corpus.


3. Criterios que guiaron la arquitectura

Las decisiones de diseño se derivaron de cinco necesidades principales: conservar la fuente original, impedir que registros inválidos contaminaran las etapas posteriores,

permitir búsqueda semántica, conservar trazabilidad entre respuestas y fuentes, y mantener aislamiento entre usuarios y conversaciones.

De estas necesidades surgió la arquitectura medallón y la separación entre el pipeline de datos y la capa de indagación.

La arquitectura general puede resumirse como:



El principio utilizado fue evitar que el modelo generativo se convirtiera en la fuente de conocimiento del sistema. El modelo interpreta una pregunta y redacta una respuesta, pero la evidencia debe proceder del corpus.

4. Pipeline de datos y arquitectura medallón

4.1 Bronze: preservar antes de transformar

La primera necesidad fue mantener una representación reproducible del material obtenido de la fuente pública.

La capa Bronze conserva los datos ingeridos antes de aplicar transformaciones semánticas. Esto permite separar los problemas de adquisición de los problemas de procesamiento y repetir etapas posteriores sin depender nuevamente de la disponibilidad o del estado actual de la fuente.

Bronze funciona, por tanto, como el punto de entrada auditable del pipeline.

4.2 Silver: validar antes de utilizar

Los registros obtenidos de una fuente externa no deben asumirse como correctos.

La capa Silver introduce contratos de datos mediante Pydantic y normaliza los campos que serán utilizados por las etapas posteriores. Los registros que no satisfacen el contrato no se incorporan silenciosamente al corpus procesado, lo que permite detectar problemas antes de generar embeddings o alimentar el sistema de recuperación.

Esta separación evita que errores estructurales de la fuente se conviertan posteriormente en errores difíciles de identificar dentro del RAG.

4.3 Gold: preparar conocimiento consultable

La capa Gold transforma el corpus validado en unidades adecuadas para recuperación.

Cada fragmento conserva los metadatos necesarios para reconstruir su procedencia y recibe una representación vectorial. En producción el corpus fue reindexado utilizando `gemini-embedding-001` con vectores de 768 dimensiones y almacenamiento en PostgreSQL con pgvector.

La capa Gold también contiene capacidades analíticas adicionales. Los embeddings pueden reducirse a tres dimensiones para visualización y utilizarse para explorar agrupaciones del corpus. Esta información permite inspeccionar su estructura temática, pero no sustituye al embedding original utilizado durante la recuperación semántica.


5. Diseño de la capa de indagación

Una decisión deliberada del proyecto fue no introducir un framework agéntico general.

El comportamiento requerido era suficientemente acotado como para implementar una capa pequeña de planificación sobre servicios ya existentes. El modelo genera un plan estructurado en JSON, el plan es validado mediante Pydantic y únicamente puede solicitar operaciones previamente autorizadas.

La superficie disponible está limitada a tres herramientas de solo lectura:

`buscar_declaraciones`, `explorar_temas` y `consultar_cluster`.



Esta allowlist reduce la capacidad del modelo para ejecutar acciones fuera del dominio del sistema y mantiene explícita la frontera entre razonamiento generado y operaciones permitidas.


El término *agente* se utiliza aquí para describir esta capacidad de seleccionar y combinar herramientas durante una indagación. No implica autonomía general ni capacidad de modificar datos o ejecutar acciones externas.

6. Recuperación, generación y evidencia

Cuando un usuario formula una pregunta, el sistema identifica la operación apropiada, ejecuta la recuperación y entrega al modelo únicamente el contexto encontrado.

La respuesta conserva las fuentes utilizadas, incluyendo información que permite volver al fragmento y a la sesión correspondiente. La interfaz presenta adicionalmente métricas como número de fuentes, similitud, latencia, tokens utilizados y modelo de generación.

Esta trazabilidad permite distinguir tres elementos que de otro modo podrían confundirse:



Una respuesta lingüísticamente convincente no constituye por sí sola evidencia de que el sistema funcionó correctamente. Por ello, la evaluación considera por separado la calidad de la recuperación y la correspondencia entre respuesta y contexto.

7. Memoria conversacional y aislamiento

La memoria se almacena por conversación y pertenece a un usuario identificado mediante JWT.

La propiedad de una conversación no procede de un identificador enviado libremente por el cliente, sino de la identidad derivada de la sesión autenticada. Una solicitud que intenta acceder a una conversación perteneciente a otro usuario recibe `404`.

La memoria tiene una retención configurada de 30 días.

Las fuentes recuperadas también se almacenan con el mensaje. De esta manera, reabrir una conversación no muestra únicamente el texto generado anteriormente, sino también la evidencia utilizada durante ese turno.


La autenticación utiliza PyJWT con HS256, cookies `HttpOnly` y `SameSite=Strict`, contraseñas protegidas mediante Argon2 y mecanismos CSRF para las operaciones correspondientes.

8. Despliegue productivo

La aplicación de demostración se desplegó utilizando Cloud Run. El almacenamiento productivo se encuentra en Neon PostgreSQL utilizando conexión TLS y pooling.

El entorno local utiliza Ollama/EmbeddingGemma y llama.cpp, mientras que el despliegue productivo utiliza servicios Gemini. Esta separación permitió desarrollar y probar localmente sin hacer depender todo el ciclo de desarrollo de servicios externos, y posteriormente verificar el comportamiento con el stack seleccionado para producción.

La infraestructura desplegable se describe mediante Terraform.



El corpus productivo fue reindexado específicamente para este entorno, evitando mezclar vectores producidos por modelos de embeddings diferentes.

9. Estrategia de evaluación

La evaluación del sistema no se limitó a comprobar que la aplicación respondiera.

Se utilizaron pruebas automatizadas para verificar comportamiento de backend y frontend, análisis estático para detectar problemas de implementación y una evaluación específica del RAG sobre un conjunto de 50 preguntas mediante LLM-as-a-Judge.

Las métricas obtenidas deben interpretarse como indicadores del comportamiento del sistema sobre ese conjunto de evaluación, no como una medición absoluta de verdad.

Chequeo	Resultado
Backend	679 pruebas aprobadas
Cobertura backend	96.33 %


Chequeo	Resultado
Frontend	<code>pnpm typecheck</code> y 47 pruebas unitarias
Calidad estática	<code>ruff</code> y <code>ty</code> sin errores
Controles de seguridad	<code>make security</code> : 16/16
Evaluación RAG	50 preguntas
Fidelidad	93.51 %
Relevancia	99.53 %
Cobertura	73.09 %
Corpus productivo	11,120 chunks
Clusters etiquetados	52
Puntos disponibles para visualización 3D	11,120

La fidelidad elevada indica que, dentro del conjunto evaluado, las respuestas permanecieron mayoritariamente vinculadas al contexto proporcionado. La cobertura inferior a las otras métricas muestra además que todavía existen casos donde la evidencia recuperada o utilizada no cubre completamente lo esperado. Este resultado se conserva como una limitación medible del sistema y no se oculta mediante una métrica agregada única.

10. Evidencia observable en el entorno productivo

10.1 Acceso restringido

El dashboard y la API de aplicación requieren autenticación. El login y el endpoint de salud constituyen las excepciones públicas previstas.




Pantalla de login

Figura 1 — El acceso al dashboard requiere una sesión autenticada.

10.2 Turno con recuperación y fuentes

Ante la pregunta «¿Qué se declaró sobre el T-MEC?», el agente seleccionó `buscar_declaraciones` y produjo una respuesta sustentada en cinco fuentes.

La interfaz permite inspeccionar fecha, participante y fragmentos recuperados, además del modelo empleado, latencia y consumo de tokens.




Turno del agente con fuentes

Figura 2 — Respuesta del agente con cinco fuentes y métricas del turno.

10.3 Exploración del corpus

El dashboard incluye una representación tridimensional de los embeddings reducidos y la información de clustering calculada sobre el corpus.




Dashboard usuario 1

Figura 3 — Memoria conversacional, fuentes y visualización de la estructura semántica.

10.4 Aislamiento entre usuarios

La demostración utiliza dos cuentas independientes. Las conversaciones creadas por uno de los usuarios no aparecen en la sesión del otro y el acceso cruzado utilizando identificadores de conversación devuelve `404`.



Dashboard usuario 2 aislado

Figura 4 — Sesión independiente sin exposición de conversaciones pertenecientes a otro usuario.

11. Caso negativo: ausencia de evidencia

Un comportamiento particularmente importante del sistema puede observarse cuando la pregunta no tiene respaldo en el corpus.

Consulta:

¿Qué dijo la presidenta sobre un viaje a Marte en 1999?

La herramienta `buscar_declaraciones` devolvió cero resultados y el sistema respondió:

No encontré evidencia suficiente en el corpus para sostener esa conclusión.

La traza registra la ejecución de la herramienta, cero resultados, estado `ok`, una latencia de 507 ms y `refusal=true`.

Este caso ilustra una decisión central de la arquitectura: **la ausencia de evidencia no debe transformarse en permiso para que el modelo complete la respuesta utilizando únicamente su conocimiento paramétrico.**

12. Reproducibilidad

La infraestructura y las principales operaciones del pipeline pueden ejecutarse mediante comandos versionados junto con el proyecto.

```
# Infraestructura
cd infra/terraform
terraform init
terraform plan
terraform apply

# Reindexación productiva
NEON_DATABASE_URL=<secret> GEMINI_API_KEY=<secret> \
  uv run python -m lakehouse pipeline reindex-production

# Sincronización de clusters y visualización 3D
NEON_DATABASE_URL=<secret> \
  uv run python -m lakehouse pipeline sync-production-visuals

# Sincronización de observabilidad
NEON_DATABASE_URL=<secret> \
  uv run python -m lakehouse pipeline sync-production-observability

# Evaluación RAG
uv run python -m lakehouse evaluate-rag

# Estimación determinista del costo de infraestructura
python3 scripts/gcp_cost.py --config scripts/gcp_cost.example.json
```

La estimación realizada para el volumen actual de la demostración produce un costo marginal mensual aproximado de USD 0 bajo las condiciones y niveles gratuitos

considerados por el script. Este valor no debe interpretarse como garantía de costo cero ante un incremento de tráfico, almacenamiento o consumo de servicios externos.

13. Límites y decisiones conscientes

RAG del pueblo recupera información contenida en el corpus, pero no determina si las declaraciones recuperadas son verdaderas.

Una respuesta puede estar correctamente sustentada y aun así citar una afirmación incorrecta realizada durante una conferencia. El sistema evalúa correspondencia entre pregunta, evidencia y respuesta; no realiza verificación factual externa.

El clustering tampoco constituye una taxonomía oficial del corpus. HDBSCAN identifica estructura estadística en la representación utilizada y las etiquetas sirven para facilitar su exploración.

La evaluación RAG se realizó sobre un conjunto de 50 preguntas y mediante un evaluador basado en LLM, por lo que sus resultados caracterizan ese experimento y no garantizan el mismo comportamiento ante cualquier pregunta posible.

Finalmente, el despliegue actual es una demostración académica con acceso restringido y no un servicio público abierto.

14. Problemas encontrados durante el despliegue

El paso de un entorno local al entorno productivo permitió detectar varios problemas que no eran visibles durante las primeras etapas de desarrollo.

El gráfico tridimensional dejó de renderizar debido a una incompatibilidad entre `echarts@6`, `echarts-gl@2.1` y la Content Security Policy configurada. La visualización fue estabilizada utilizando `echarts@5.6` y permitiendo el mecanismo requerido por `claygl` exclusivamente para esa funcionalidad.

También se detectó que las corridas del pipeline ejecutadas localmente no aparecían en la observabilidad del entorno productivo. Para resolverlo se añadió el comando `sync-production-observability`, que replica la información requerida hacia Neon.

Finalmente, las primeras versiones de la memoria conservaban la respuesta generada pero no toda la evidencia asociada. Se modificó la persistencia para almacenar también `sources`, `cluster_id`, `embedding_3d` y `latency_ms`. Al reabrir una conversación ahora es posible reconstruir tanto la respuesta como las fuentes utilizadas y su relación con la visualización.

Estos problemas resultaron útiles porque evidenciaron una diferencia importante entre construir una demostración funcional y construir un sistema cuyo comportamiento pueda ser inspeccionado después de ejecutarse.

15. Experiencia y aprendizajes

El principal aprendizaje del proyecto fue que la construcción de un sistema RAG no comienza ni termina con la selección de un modelo generativo.

Antes de generar una respuesta fue necesario resolver adquisición, conservación, validación, fragmentación, representación vectorial, indexación y recuperación. Después de generarla fue necesario resolver trazabilidad, memoria, aislamiento, evaluación, observabilidad y despliegue.

La arquitectura medallón resultó particularmente útil porque convirtió estos problemas en responsabilidades separadas. Bronze conserva el origen, Silver protege la calidad estructural y Gold prepara información para distintos usos, entre ellos la recuperación semántica y el análisis exploratorio.

Otro aprendizaje fue distinguir capacidades que inicialmente parecían formar parte de un mismo problema. La visualización tridimensional y el clustering permiten estudiar el corpus, pero el RAG no depende de ellos para responder. Del mismo modo, la memoria mejora una investigación de varios turnos, pero no sustituye a la recuperación de evidencia.

Finalmente, el despliegue productivo permitió comprobar que la calidad de un sistema de IA aplicada también depende de elementos tradicionales de ingeniería: autenticación,

persistencia, pruebas, contratos, observabilidad, infraestructura reproducible y manejo de errores.

16. Conclusiones

RAG del pueblo demuestra una arquitectura en la que un modelo generativo constituye sólo una parte de un sistema mayor.

El pipeline permite conservar y transformar un corpus público; la capa Gold lo convierte en información recuperable semánticamente; el sistema de indagación selecciona herramientas de consulta; y el modelo genera una respuesta utilizando evidencia explícita que puede inspeccionarse posteriormente.

Los resultados obtenidos muestran un comportamiento favorable en fidelidad y relevancia, aunque también exponen oportunidades de mejora, particularmente en cobertura. La existencia de estas métricas permite convertir futuras modificaciones en hipótesis evaluables en lugar de depender únicamente de apreciaciones subjetivas sobre la calidad de las respuestas.

El resultado final no pretende sustituir la investigación humana. Su propósito es reducir el costo de localizar información y facilitar que una afirmación generada pueda regresar a su fuente.

Desde la perspectiva del diplomado, el proyecto permitió integrar ingeniería de datos, representaciones vectoriales, recuperación de información, modelos generativos, evaluación, seguridad, observabilidad y despliegue en un mismo sistema verificable.

Apéndice A – Credenciales demo (únicamente en este documento)

Usuario	Contraseña
usuario_demo_1	YeB2aV2)nQ##28i8VjZ2hBro
usuario_demo_2	fiX9}j?cFZr:Ae?r6da>3JDP